

Proyecto 1 — Segmentación y clasificación del estado de madurez de tomates

INFO1185: Inteligencia Artificial

Prof. Dr. Ricardo Soto Catalán

1. Propósito

Desarrollar un sistema para la identificación del estado de madurez de tomates en imágenes, integrando técnicas de aprendizaje no supervisado y supervisado.

El proyecto contempla dos etapas principales:

1. **Segmentación del fruto:** utilizar K-Means para separar automáticamente los píxeles correspondientes al tomate de aquellos pertenecientes al fondo.
2. **Clasificación del estado de madurez:** utilizar un clasificador bayesiano para determinar si el fruto segmentado corresponde a un tomate maduro o inmaduro.

Adicionalmente, se deberá analizar el efecto de diferentes estrategias de **selección de características** y de la **reducción de dimensionalidad mediante Análisis por Componentes Principales (PCA)** sobre el desempeño del clasificador.

2. Datos

Se utilizará el conjunto de datos *Ripe and Unripe Tomatoes Dataset*, compuesto por imágenes RGB de tomates maduros e inmaduros y sus respectivas anotaciones.

Los datos deberán dividirse **por imagen y no por píxel** en:

- Entrenamiento: 60 %.
- Validación: 20 %.
- Test: 20 %.

La partición deberá realizarse utilizando una semilla fija y documentada.

Los conjuntos de entrenamiento y validación podrán utilizarse para tomar decisiones de diseño, seleccionar características, ajustar PCA y determinar el punto de operación de los clasificadores. El conjunto de test deberá utilizarse exclusivamente para la evaluación final.

3. Tareas obligatorias

3.1. Exploración de los datos

Realice un análisis exploratorio de las imágenes y de las características disponibles.

Como mínimo, analice los canales:

$$R, \quad G, \quad B.$$

Puede incorporar otras representaciones de color que considere pertinentes, tales como HSV. Presente histogramas, estadísticos y/o visualizaciones que permitan caracterizar los datos y analizar las diferencias observadas entre:

- fruto y fondo;
- tomates maduros e inmaduros.

Las observaciones obtenidas en esta etapa deberán ser utilizadas posteriormente para justificar una de las estrategias de selección de características del clasificador bayesiano.

3.2. Segmentación mediante K-Means

Desarrolle un procedimiento para segmentar automáticamente los tomates mediante **K-Means**.

Considere como características los canales RGB y evalúe **todas las combinaciones no vacías posibles**:

$$R, \quad G, \quad B, \quad RG, \quad RB, \quad GB, \quad RGB.$$

Para cada combinación:

1. Aplique K-Means para separar el fruto del fondo.
2. Determine cuál de los clusters obtenidos corresponde al tomate.
3. Compare la máscara obtenida con la máscara de referencia.
4. Calcule el índice de Jaccard:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

Reporte el desempeño obtenido para las siete combinaciones y seleccione aquella que presente el mejor desempeño. La selección deberá estar justificada a partir de los resultados experimentales.

Se deberán documentar:

- número de clusters utilizado;
- estrategia de inicialización;
- criterio de convergencia;
- semilla utilizada;
- procedimiento utilizado para determinar cuál cluster corresponde al fruto.

Incluya ejemplos visuales representativos de las segmentaciones obtenidas.

3.3. Extracción de características del fruto

Utilizando la mejor configuración de segmentación obtenida en la etapa anterior, extraiga características representativas de cada fruto.

Como mínimo, considere los valores medios de los canales RGB calculados exclusivamente sobre los píxeles pertenecientes a la región segmentada:

$$\bar{R}, \quad \bar{G}, \quad \bar{B}.$$

Puede incorporar otras características que considere pertinentes. Por ejemplo, utilizando una transformación al espacio HSV:

$$\bar{H}, \quad \bar{S}, \quad \bar{V}.$$

De esta forma, un fruto podría quedar representado, por ejemplo, mediante:

$$\mathbf{x} = [\bar{R}, \bar{G}, \bar{B}, \bar{H}, \bar{S}, \bar{V}].$$

Toda característica incorporada deberá ser descrita y justificada.

3.4. Selección de características y clasificación bayesiana

Desarrolle clasificadores bayesianos que permitan distinguir entre:

Tomate maduro y Tomate inmaduro.

Los clasificadores deberán operar sobre características obtenidas exclusivamente de la región del fruto determinada mediante la etapa de segmentación.

Se deberán desarrollar y comparar **dos estrategias obligatorias de selección de características**.

3.4.1. Selección basada en el análisis de las características

A partir del análisis exploratorio realizado, seleccione un subconjunto de características que considere adecuado para distinguir tomates maduros e inmaduros.

La selección deberá estar fundamentada mediante las distribuciones, estadísticas y/o visualizaciones obtenidas. Explique:

- qué características fueron seleccionadas;
- qué diferencias se observan entre ambas clases;
- por qué espera que las características seleccionadas permitan discriminar entre tomates maduros e inmaduros.

Utilizando las características seleccionadas, desarrolle un primer clasificador bayesiano.

3.4.2. Selección mediante un método de selección de características

Seleccione un segundo subconjunto de características utilizando **una** de las siguientes técnicas estudiadas en el curso:

- Correlation-based Feature Selection (CFS).
- Sequential Forward Feature Selection (SFS).

Describa el procedimiento utilizado, el criterio de selección y las características finalmente seleccionadas.

Utilizando este subconjunto, desarrolle un segundo clasificador bayesiano.

Compare:

Bayes + selección basada en análisis

con

Bayes + CFS/SFS.

Analice si las características seleccionadas mediante CFS o SFS coinciden con aquellas identificadas a partir del análisis exploratorio y discuta las posibles razones de las diferencias encontradas.

3.5. Criterio de decisión de los clasificadores bayesianos

Para los clasificadores bayesianos, diseñe la regla de decisión mediante razón de verosimilitudes y analice su desempeño para diferentes umbrales.

Construya la curva ROC correspondiente y seleccione un punto de operación utilizando uno de los siguientes criterios:

- Índice de Youden.
- Equal Error Rate (EER).
- Otro criterio debidamente fundamentado.

El criterio seleccionado deberá estar claramente justificado.

Para cada configuración evaluada reporte, como mínimo:

- curva ROC;
- AUC;
- exactitud;
- sensibilidad;
- especificidad;
- criterio utilizado para seleccionar el umbral;
- punto de operación seleccionado.

3.6. Clasificación utilizando PCA

Aplique **Análisis por Componentes Principales (PCA)** sobre el conjunto de características disponible para representar cada fruto.

Analice:

- valores propios;
- porcentaje de varianza explicada por cada componente;
- varianza explicada acumulada.

Seleccione el número de componentes principales que utilizará para realizar la clasificación.

La cantidad de componentes deberá ser determinada y justificada por cada grupo a partir del análisis de la varianza explicada.

Posteriormente, desarrolle un nuevo clasificador bayesiano utilizando únicamente las componentes principales seleccionadas:

$$\mathbf{x} \xrightarrow{PCA} [PC_1, \dots, PC_p] \xrightarrow{Bayes} \{\text{maduro, inmaduro}\}.$$

Utilice el mismo procedimiento de evaluación y selección del punto de operación empleado en los clasificadores anteriores.

3.7. Comparación final

Compare experimentalmente las tres estrategias de clasificación:

Bayes + selección basada en análisis

Bayes + CFS/SFS

PCA + Bayes

.

La comparación deberá realizarse bajo las mismas condiciones experimentales y utilizando las mismas métricas.

En su análisis responda, al menos, las siguientes preguntas:

1. ¿Qué combinación de canales RGB produjo la mejor segmentación mediante K-Means?
2. ¿Por qué considera que dicha combinación produjo un mejor resultado?
3. ¿Qué características del fruto permiten diferenciar mejor tomates maduros e inmaduros según el análisis exploratorio?
4. ¿Qué características fueron seleccionadas mediante CFS o SFS? ¿Coinciden con las seleccionadas a partir del análisis exploratorio?
5. ¿Qué estrategia de selección de características produjo el mejor clasificador bayesiano?
6. ¿Qué criterio se utilizó para determinar el punto de operación y por qué?
7. ¿Cuántas componentes principales fueron utilizadas y cómo se justificó esta decisión?
8. ¿El uso de PCA mejoró el desempeño respecto de los clasificadores construidos con características seleccionadas?
9. ¿Cómo afecta la calidad de la segmentación mediante K-Means al desempeño posterior del clasificador de madurez?

4. Reglas y buenas prácticas

- Evitar *data leakage*: normalización, selección de características y PCA deberán ajustarse utilizando únicamente los datos correspondientes al proceso de desarrollo.
- El conjunto de test no podrá utilizarse para seleccionar características, número de componentes principales, umbral de decisión u otros parámetros.

- La partición de los datos deberá realizarse por imagen y no por píxel.
- Fijar y documentar las semillas utilizadas.
- Documentar claramente los parámetros relevantes de K-Means y de los clasificadores bayesianos.
- La evaluación final deberá realizarse sobre el conjunto de test.
- Todas las decisiones metodológicas relevantes deberán estar justificadas mediante evidencia experimental.

5. Preguntas centrales del proyecto

El desarrollo deberá permitir responder experimentalmente:

¿Qué combinación de características permite segmentar de mejor forma los tomates mediante K-Means?

¿Qué características permiten distinguir mejor tomates maduros e inmaduros mediante un clasificador bayesiano?

¿Qué diferencias existen entre seleccionar las características a partir del análisis exploratorio y seleccionarlas mediante CFS o SFS?

¿La transformación de las características mediante PCA mejora el desempeño respecto del uso de las características seleccionadas?

¿Cómo influye la calidad de la segmentación en el desempeño final de clasificación?

6. Entregables

1. Código (15 pts).
2. PowerPoint o similar (85 pts)

6.1. Entrega y formato

- Formato: archivo ZIP con carpeta data, scripts desarrollados e informe en PDF.
- Fecha de entrega: Miércoles 16 de Septiembre a las 23.59 hrs.

6.2. Observaciones

El proyecto se debe desarrollar en parejas, usted es libre de elegir con quién trabajar. Contempla la entrega de informe y códigos, cuya nota es ponderada por un factor de presentación (FP) la cuál depende del desempeño de la dupla en una entrevista sobre su desarrollo.

Esta entrevista se realizará durante la semana del 21 de septiembre mediante agendamiento. De modo que, su calificación se calcula como:

$$NP1 = FP \cdot (\text{Nota PowerPoint} + \text{código}), \quad (1)$$

donde Nota informe + código se calcula según la Rúbrica que se muestra en la Sección 7, y FP de acuerdo con la Rúbrica de entrevista, que se presenta en la Sección 8.